

# Semana 3. Mínimos Cuadrados Ordinarios

Equipo Econometría Avanzada

Universidad de los Andes

26 de agosto de 2022



# Contenido

- 1 Contexto y pregunta de investigación
- 2 MCO
- 3 Inferencia Estadística
- 4 Corrección de errores estándar

# Contexto

Bryan et al. (2021) utilizan información de personas pertenecientes a comunidades evangélicas pentecostales vulnerables de Filipinas.

- Aleatoriamente se seleccionaron 320 comunidades religiosas para ser invitadas a un programa sobre valores cristianos.
- El programa consistió en 15 sesiones semanales.
- El currículo enseñó la “bondad del mundo material” e incentiva el ahorro, el no malgastar dinero, y el no apostar ni beber.

# Pregunta de investigación

¿Cuál es el efecto de la asignación al programa de valores cristianos ( $D$ ) sobre la religiosidad ( $Y^1$ ) y el salario ( $Y^2$ )?


Considere el siguiente modelo de regresión:

$$Y_i^j = \alpha_0^j + \alpha_1^j D_i + u_i^j,$$

con  $j = \{1, 2\}$

- ¿Qué contienen los términos  $u_i^1$  y  $u_i^2$ ?

# El modelo de regresión lineal



# Mínimos Cuadrados Ordinarios (MCO)

## Estimación

Para un modelo generalizado,  $Y = X\alpha + U$ , el estimador de MCO de  $\alpha$  es:

$$\begin{aligned}\hat{\alpha}_{MCO} &= \arg \min_{\hat{\alpha}} \hat{U}' \hat{U} \\ &= \arg \min_{\hat{\alpha}} \sum_{i=1}^N \hat{U}_i^2\end{aligned}$$

$$\hat{\alpha}_{MCO} = (X'X)^{-1} X'Y$$

- **Outcome predicho:**

$$\hat{Y} = X\hat{\alpha}$$

- **Término de error predicho:**

$$\hat{U} = Y - \hat{Y}$$

Pilas: Modelo  $\neq$  Método de estimación





# MCO

## Propiedades del estimador de MCO

En general, para un modelo

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik} + \epsilon_i$$

El estimador del vector de coeficientes  $\beta$  por MCO,  $\hat{\beta}_{MCO}$ , tiene las siguientes propiedades:

- **(Insesgamiento):** Es insesgado siempre que  $\mathbb{E}[\epsilon_i|X] = 0$ .  
(Exogeneidad estricta)
- **(Consistencia):** Es consistente siempre que  $Cov(x_i, \epsilon_i) = \mathbb{E}[x_i \epsilon_i] = 0$  (No correlación)
- **(Eficiencia):** Es el estimador MELI si:
  - ▶  $\mathbb{E}[\epsilon_i|X] = 0$ . (Exogeneidad estricta)
  - ▶  $Var(\epsilon_i) = \sigma^2 \forall i$  (Homocedasticidad)
  - ▶  $Cov(\epsilon_i, \epsilon_j) = 0 \forall i \neq j$  (No autocorrelación)
- ¿Qué supuesto es más débil entre exogeneidad estricta o no correlación?
- ¿Es razonable pensar que  $\hat{\alpha}_{1,MCO}^j$  es insesgado y consistente?
- ¿Es razonable pensar que es el estimador MELI?

# MCO

## Estimadores particulares

El estimador de MCO toma formas particulares en función de la cantidad y naturaleza de los regresores. Algunas son:

- 1 Cuando  $X$  es de tamaño  $(N \times 1)$  y solo contiene una columna de 1s:

$$Y = \alpha_0 + U$$

$$\hat{\alpha}_{0,MCO} = \bar{Y}$$

- 2 Cuando  $X$  es de tamaño  $(N \times 2)$  y contiene una columna de 1s y una columna con  $D$  (dummy):

$$Y = \alpha_0 + \alpha_1 D + U$$

$$\hat{\alpha}_{1,MCO} = \bar{Y}_1 - \bar{Y}_0$$

- 3 Cuando  $X$  es de tamaño  $(N \times 2)$  y contiene una columna de 1s y una columna con  $x_1$  (continua):

$$Y = \alpha_0 + \alpha_1 x_1 + U$$
$$\hat{\alpha}_{1,MCO} = \frac{\widehat{Cov}(Y, x_1)}{\widehat{Var}(x_1)}$$

**Nota:** Bajo el supuesto de que  $\mathbb{E}[U|x_1] = 0$ , entonces

$$\alpha_1 = \frac{\partial \mathbb{E}[Y|x_1]}{\partial x_1}$$

esto es, es el efecto marginal de incrementar/disminuir  $x_1$  **en el promedio** de  $Y$ .

Cuando  $X$  es de tamaño  $(N \times k)$ :

$$Y = \alpha_0 + \alpha_1 D + x\beta + U \quad (1)$$

¿Cuál es la interpretación de  $\hat{\alpha}_1$  en este contexto?

La manera más adecuada para interpretar este coeficiente se deriva del Teorema de Waugh-Frisch-Lovell, conocido como el método de “partialling-out”.

“Partialling-out” nos permite entender qué hacen los controles y por qué son importantes.

### Teorema de Waugh-Frisch-Lovell

Considere el modelo (1)

$$Y = \alpha_0 + \alpha_1 D + x\beta + U \quad (1)$$

junto con los siguientes modelos

$$D = \gamma_0 + x\gamma_1 + \eta \quad (2)$$

$$Y = \mu_0 + x\mu_1 + \xi \quad (3)$$

$$\hat{\xi} = \zeta_0 + \zeta_1 \hat{\eta} + \varepsilon \quad (4)$$

Entonces  $\hat{\alpha}_{1,MCO} = \hat{\zeta}_{1,MCO}$ .

[Ver simulación](#)

# Otros supuestos: matriz de varianza y covarianza (VarCov)



$$\Sigma = \text{Var}(\epsilon|\mathbf{X}) = \mathbb{E}[\epsilon\epsilon'|\mathbf{X}] = \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} & \dots & \sigma_{1n-1} & \sigma_{1n} \\ \sigma_{21} & \sigma_{22}^2 & \dots & \sigma_{2n-1} & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \sigma_{n-11} & \sigma_{n-12} & \dots & \sigma_{n-1n-1}^2 & \sigma_{n-1n} \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_{nn-1}^2 & \sigma_{nn}^2 \end{bmatrix}_{N \times N}$$

Matriz cuadrada ( $N \times N$ ), contiene las varianzas y covarianzas de los términos de error de  $N$  observaciones

- La diagonal principal contiene las varianzas de los errores.
- Fuera de la diagonal están las covarianzas entre los errores de las distintas observaciones.
- ¿Cómo se ve la VarCov cuando se cumple el supuesto de homoscedasticidad y no autocorrelación?
- ¿Y cómo se ve cuando se cumple el supuesto de no autocorrelación pero no el de homoscedasticidad? ¿Y cuando se cumple el supuesto de homoscedasticidad pero no el de no autocorrelación?

# Inferencia Estadística

## Heterocedasticidad



Heterocedasticidad:  $Var(\epsilon_i|X) \neq \text{constante}$

- **Problema:** Podemos sobre o subestimar los errores. No hay una regla general, pues depende de la relación entre el error y la variable independiente.
  - ▶ Esto invalida la inferencia estadística.
- **Solución:** Usar errores estándar robustos de White (en muestras grandes).
  - ▶ Esto valida la inferencia estadística en presencia de heteroscedasticidad. **No la elimina.** MCO sigue siendo ineficiente.

# Inferencia Estadística

## Auto-correlación

*Auto-correlación:*  $cov(\epsilon_i \epsilon_j | X) \neq 0$  dado que  $i \neq j$

- **Problema:** Subestima los errores estándar.
  - ▶ Esto invalida la inferencia estadística.
- **Solución:** Errores estándar robustos a correlación a nivel de clúster (se sugieren 50 o más clusters).
  - ▶ Esto valida la inferencia estadística en presencia de autocorrelación. **No la elimina.** MCO sigue siendo ineficiente.
- ¿En qué situaciones pueden comúnmente surgir problemas de autocorrelación?



# Inferencia Estadística

## Pruebas de Hipótesis

En general, el no corregir la estimación de los errores en presencia de heteroscedasticidad y/o autocorrelación resulta en:

- Estimadores sesgados de la varianza de los estimadores.
- Intervalos de confianza más grandes o pequeños de los reales.

Por ende, **podemos llegar a conclusiones incorrectas**. Entonces, en muchos casos, hace falta usar errores estándar robustos para realizar inferencia estadística correctamente.

- ¿Entonces nunca se deben usar los errores estándar clásicos?

# Corrección de errores

## 1 Heteroscedasticidad:

- ▶ Mínimos Cuadrados Ponderados (MCP) o Mínimos Cuadrados Generalizados (MCG).
  - ★ Funciona en caso de conocer la forma funcional de la heteroscedasticidad.
  - ★ Esto sí corrige el problema de heteroscedasticidad.
- ▶ Errores estándar de White en el resto de situaciones.

## 2 Autocorrelación:

- ▶ Mínimos Cuadrados Generalizados (MCG) o Mínimos Cuadrados Factibles (MCF).
  - ★ Funciona en caso de conocer la forma funcional de la autocorrelación.
  - ★ Esto sí corrige el problema de autocorrelación.
- ▶ Errores estándar robustos a correlación a nivel de clúster.
- ▶ ¿Cuándo corregir por errores estándar cluster?
  - ★ Si el proceso de muestreo fue clusterizado.
  - ★ La asignación al tratamiento fue clusterizada.

¿Hay alguna otra alternativa? Sí, el cálculo de errores estándar mediante la metodología de *Bootstrap*.

¡Gracias!