

# Semana 5. Regresión Discontinua Nítida

Equipo Econometría Avanzada

Universidad de los Andes

9 de septiembre de 2022



# Contenido

- 1 Contexto y pregunta de investigación
- 2 Definición
- 3 Validando el supuesto de identificación
- 4 Estimación
- 5 Conclusión

# Contexto

Meyersson (2014) utiliza datos de Turquía en 1994 para estudiar si el control político por parte de un partido islámico tiene efectos sobre el acceso a la educación de las mujeres.

- Múltiples candidatos del partido Islámico ganaron las elecciones locales de 1994 en Turquía.
- El alcalde elegido es aquel candidato que obtiene la mayoría de votos.
- El **margen de votos** del candidato del partido islámico es la diferencia entre los votos dicho candidato y el (*otro*) candidato con mayor número de votos.
- Si el **margen de votos es positivo** el candidato del partido islámico fue elegido como alcalde.

# Pregunta de investigación

¿Cuál es el efecto del control político por parte de un partido islámico ( $D_i$ ) sobre el acceso a la educación de las mujeres ( $y_i$ )?

$$y_i = \rho D_i + f(x_i) + u_i$$

donde, para cada municipio  $i$ ,

- $y_i$ : proporción de mujeres entre 15 y 20 años con educación completa.
- $x_i$ : margen de votos del partido islámico.
- $f(\cdot)$ : función suave de  $x_i$
- $D_i = \mathbb{1}[x_i \geq 0]$ .

# Regresión discontinua nítida

El tratamiento es una función **discontinua** y **determinística** de una variable  $x_i$  (variable de focalización, *running variable* o *forcing variable*).


Por ejemplo,

$$D_i = \begin{cases} 1 & \text{si } x_i \geq x_0 \\ 0 & \text{si } x_i < x_0 \end{cases} \quad (1)$$

donde  $x_0$  es el corte que determina el tratamiento.

- También puede ser el caso de que  $D_i = \mathbb{1}[x_i \leq x_0]$ .
- No hay **ningún** valor de  $x_i$  en el que se observen tratados y no tratados al mismo tiempo.

Es decir, en RDN hay un **salto determinístico en la probabilidad de tratamiento**: La probabilidad de ser tratado salta de 0 a 1 (o de 1 a 0) cuando se pasa de un lado a otro del umbral.



Ya veremos qué pasa cuando el salto no es determinístico.

# La idea

En términos poblacionales, el efecto de interés está dado por

$$ATE(X_i) = \mathbb{E}[Y_i(1) - Y_i(0)|X_i]$$

No obstante, el problema fundamental de la identificación causal es que no observamos  $Y_i(1)$  y  $Y_i(0)$  al mismo tiempo para ningún individuo.

En el caso particular de RD, en términos poblacionales

$$\mathbb{E}[Y_i|X_i] = \begin{cases} \mathbb{E}[Y_i(1)|X_i] & \text{si } X_i \geq x_0 \\ \mathbb{E}[Y_i(0)|X_i] & \text{si } X_i < x_0 \end{cases} \quad (2)$$

Es decir, para ningún valor de  $X_i = x_i$  observaremos tanto  $\mathbb{E}[Y_i(1)|X_i = x_i]$  como  $\mathbb{E}[Y_i(0)|X_i = x_i]$ .




Figure 2: RD Treatment Effect in Sharp RD Design



- Gráficamente, el efecto causal  $ATE(x_i)$  es la diferencia entre la curva roja y la curva azul para un valor de  $X_i = x_i$ . Esto es imposible de calcular en la práctica, pues en la región que observamos la curva roja, no observamos la azul, y viceversa. Sin embargo, algo especial pasa en  $X_i = x_0$ : casi vemos ambas curvas  $\mathbb{E}[Y_i(1)|X_i]$  y  $\mathbb{E}[Y_i(0)|X_i]$  simultáneamente.
- Así, si encontráramos la manera de calcular ambas funciones en  $X_i = x_0$  ( $\mu^+$  y  $\mu^-$  en la figura), podríamos estimar el efecto causal ( $ATE(X_i)$ ) en dicho punto. La clave para lograrlo es la **continuidad local**.

# Continuidad local

**Supuesto:** Las funciones de los resultados potenciales promedio condicionales en la variable de focalización,  $E[Y_i(1)|X_i = x]$  y  $E[Y_i(0)|X_i = x]$ , son continuas en el punto  $x = x_0$ .

Bajo este supuesto podemos identificar  $ATE(x_0)$ :

$$\begin{aligned}\tau_{RDN} &= \lim_{x \downarrow x_0} \mathbb{E}[Y_i|X_i = x] - \lim_{x \uparrow x_0} \mathbb{E}[Y_i|X_i = x] \\ &= \lim_{x \downarrow x_0} \mathbb{E}[Y_i(1)|X_i = x] - \lim_{x \uparrow x_0} \mathbb{E}[Y_i(0)|X_i = x] \\ &= \mathbb{E}[Y_i(1) - Y_i(0)|X_i = x_0]\end{aligned}$$

El anterior es el efecto causal del tratamiento *para aquellos individuos tales que*  $X_i = x_0$ . Esto se conoce como un **Local Average Treatment Effect (LATE)**.


# Supuesto de identificación

Si las funciones de resultados potenciales condicionales en  $X_i$  son continuas en  $x_0$ , debe ser que:


- ❶ Las funciones del valor esperado condicional de las covariables también son continuas en el punto  $x_0$ .
  - ▶ Los demás determinantes de la variable de resultado no cambian abruptamente en  $x_0$ .
- ❷ La densidad de individuos a un lado o el otro del corte es aproximadamente igual.
  - ▶ Los individuos no pueden manipular el puntaje de su variable de focalización para quedar a un lado o el otro del corte.
  - ▶ Saltos en la densidad de individuos de un lado al otro hace que los resultados sean menos creíbles.

**¡Estas condiciones pueden ser verificadas empíricamente!**

**Continuidad local de otros confounders:** Las variables observadas no deben presentar ningún salto en el punto de corte. Esto sugiere que las funciones de resultados potenciales condicionales en  $X_i$  son efectivamente continuas.




Continuidad local




No continuidad local

**No manipulación:** No hay discontinuidad la función de densidad de  $X_i$  en  $x_0$ . Esto sugiere que las unidades justo debajo del corte son comparables a las unidades justo después.



No manipulación




Manipulación

- Ejemplo de manipulación del puntaje SISBEN en Colombia: [Camacho y Conover \(2011\)](#) pág. 43.

# Estimación paramétrica: regresión lineal


$$Y_i = f(X_i - x_0) + \rho D_i + u_i \quad (3)$$

- Escenario lineal



$$\begin{aligned} f(X_i) &= \alpha_1 X_i \text{ ó} \\ f(X_i) &= \alpha_1 X_i + \delta_1 X_i D_i \\ f(X_i) &= \alpha_1 X_i + \alpha_2 X_i^2 \text{ ó} \end{aligned}$$


- Escenario no lineal



$$f(X_i) = \alpha_1 X_i + \alpha_2 X_i^2 + \delta_1 X_i D_i + \delta_2 X_i^2 D_i$$

# Importancia de la forma funcional

La mala especificación de  $f(\cdot)$  puede llevar a conclusiones erradas:



- Si hay dos programas que se asignan con el mismo punto de corte, ¿tendría esto implicaciones en la identificación del efecto de uno de los programas?

# Estimación no paramétrica: polinomios locales

- Realmente el objetivo de la regresión discontinua es hallar el valor de la discontinuidad, no la forma funcional del valor esperado de  $Y$  condicional en  $X$ . Esto es, queremos aproximar:

$$\tau = \lim_{\eta \downarrow 0} \mathbb{E}[Y|X_i = x_0 + \eta] - \lim_{\eta \uparrow 0} \mathbb{E}[Y|X_i = x_0 + \eta]$$

- La estimación por MCO busca una aproximación global del valor esperado condicional. Esto supone dos problemas:
  - ▶ Las aproximaciones globales son malas para ajustar los extremos del intervalo donde se aproxima (fenómeno de Runge).
  - ▶ La regresión pesa a todas las observaciones por igual, aun cuando nos interesan más las observaciones cerca al umbral.
- Por esto la literatura ha convergido en que la estimación más adecuada es a través de polinomios locales. Esta metodología puede usarse en Stata o en R usando el comando *rdrobust* desarrollado por [Calonico, Cattaneo, Titiunik \(2014\)](#).



# ¿Cómo funcionan los polinomios locales?

Para realizar una estimación de un polinomio local de grado  $p \geq 0$ , realizamos un esquema de mínimos cuadrados pesados por un “kernel”  $K(\cdot)$  en un ancho de banda  $h > 0$ .

Entonces a la derecha del umbral resolvemos:

$$\min_{\hat{\mu}_+, \hat{\mu}_{+,j}} \sum_{i=1}^n K\left(\frac{X_i - x_0}{h}\right) \left[ y_i - \hat{\mu}_+ - \sum_{j=1}^p \hat{\mu}_{+,j} (X_i - x_0)^j \right]^2 \mathbb{1}[X_i \in (x_0, x_0 + h)]$$

y a la izquierda:

$$\min_{\hat{\mu}_-, \hat{\mu}_{-,j}} \sum_{i=1}^n K\left(\frac{X_i - x_0}{h}\right) \left[ y_i - \hat{\mu}_- - \sum_{j=1}^p \hat{\mu}_{-,j} (X_i - x_0)^j \right]^2 \mathbb{1}[X_i \in (x_0 - h, x_0)]$$

Finalmente:

$$\hat{\tau}_{RDD} = \hat{\mu}_+ - \hat{\mu}_-; \quad (\hat{\tau}_{RDD} - \tau) \xrightarrow{d} \mathcal{N}(\mathcal{B}, \Sigma)$$

Podemos estimar el sesgo  $\hat{\mathcal{B}}$ , y corregir por él:  $\hat{\tau}_{\text{Bias-corrected}} = \hat{\tau}_{RDD} - \hat{\mathcal{B}}$ .


# ¿Cómo elegir los parámetros?

- **Grado del polinomio ( $p$ ):** [Gelman & Imbens \(2016\)](#) sugieren usar  $p = 1, 2$ . (Mejora eficiencia del estimador y la cobertura de los intervalos de confianza)
- **Ancho de Banda ( $h$ ):** Equilibrar el *trade-off* sesgo-varianza. La manera más famosa de hacerlo es minimizar el error cuadrático medio (ECM):

$$\text{ECM} = \text{Sesgo} + \text{Varianza}$$

Un chequeo adicional es que el efecto estimado no sea altamente sensible a  $h$ .

- **Kernel ( $K(\cdot)$ ):** [Cattaneo, Idrobo, Titiunik \(2019\)](#) argumentan que usar un kernel triangular en conjunto con un ancho de banda elegido por minimización del ECM resulta en estimadores con propiedades óptimas.



Tipos de Kernels. [Cattaneo, Idrobo, Titiunik \(2019\)](#)

# Localidad del efecto

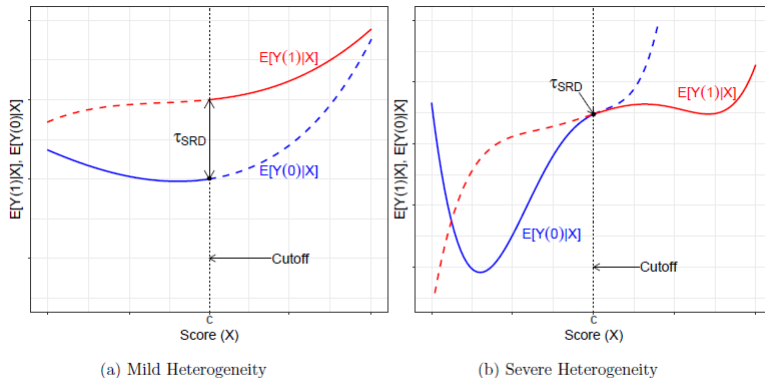


Figure 4: Local Nature of the RD Effect

El efecto al final es local porque no sabemos cómo sería el salto en otros puntos distintos a  $x_0$ .

# Simulador de RDD

- [Simulador de RDD para que jueguen.](#)

# Conclusión

- En RDN, calculamos el efecto local de una política que asigna un tratamiento mediante una regla particular: una unidad es tratada *si, y solo si*, un atributo suyo (modelado como una variable continua) es mayor a un valor exógeno llamado umbral.
- La ecuación (3) se estima por MCO o por polinomios locales en una vecindad cercana al umbral.
- En la elección del ancho de banda hay un *trade-off* entre sesgo y varianza.
  - ▶ Este sesgo se da por el [fenómeno de Runge](#).
- Actualmente, RDN es una de las metodologías más robustas pues podemos validar bastante bien el supuesto de identificación.
- El enfoque tradicional de RDN que revisamos hoy está basado en la continuidad de  $E[Y_i(d)|X_i = x]$  para  $d \in \{0, 1\}$  en el umbral.
  - ▶ Hay un enfoque alternativo que se basa en la aleatorización local que existe de estar a justo un lado o el otro del corte.
  - ▶ Los supuestos asociados a este enfoque son distintos.
  - ▶ Ver [Cattaneo, Titiunik y Vazquez-Bare \(2017\)](#) para una discusión detallada.

¡Gracias!